

The Fastest $\ell_{\infty,1}$ Prox in the West

Béjar, Benjamín and Dokmanić, Ivan and Vidal, René

汇报人: Apple Zhang

Shenzhen University

2022年9月13日

目录

- 1 Our Problem
- 2 Preliminary
- 3 Methodology
- 4 Experiments

目录

- 1 Our Problem
- 2 Preliminary
- 3 Methodology
- 4 Experiments

Sparse regression with $L_{\infty,1}$ constraints

求解以下的回归模型[?]:

$$\min_{\mathbf{W}} \|\mathbf{Y} - \mathbf{X}\mathbf{W}\|_2^2, \quad \text{s.t. } \|\mathbf{W}\|_{\infty,1} \leq \tau. \quad (1)$$

Recall $L_{p,q}$ -norm

$L_{p,q}$ 范数的定义

$$\|\mathbf{W}\|_{p,q} = \left(\sum_{i=1}^m \|\mathbf{w}^{(i)}\|_p^q \right)^{1/q} \quad (2)$$

我们常用的 $L_{2,1}$ 范数:

$$\|\mathbf{W}\|_{2,1} = \sum_{i=1}^m \|\mathbf{w}^{(i)}\|_2 \quad (3)$$

本文将用到的 $L_{\infty,1}$ 、 $L_{1,\infty}$ 范数:

$$\|\mathbf{W}\|_{\infty,1} = \sum_{i=1}^m \|\mathbf{w}^{(i)}\|_{\infty} = \sum_{i=1}^m \max_{j=1,2,\dots,c} |w_{ij}|, \quad (4)$$

$$\|\mathbf{W}\|_{1,\infty} = \max_{i=1,2,\dots,m} \|\mathbf{w}^{(i)}\|_1. \quad (5)$$

目录

1 Our Problem

2 Preliminary

3 Methodology

4 Experiments

KKT conditions for convex problems

对于以下优化问题, 其中 $f_i(\mathbf{x})$, $i = 0, 1, \dots, m$ 均为凸函数.

$$\min_{\mathbf{x}} f_0(\mathbf{x}), \quad \text{s.t. } f_i(\mathbf{x}) \leq 0 \ (i = 1, 2, \dots, m), \quad \mathbf{Ax} = \mathbf{b}. \quad (6)$$

拉格朗日函数

$$L(\mathbf{x}, \boldsymbol{\alpha}, \boldsymbol{\beta}) = f_0(\mathbf{x}) + \sum_{i=1}^m \alpha_i f_i(\mathbf{x}) + \boldsymbol{\beta}^\top (\mathbf{b} - \mathbf{Ax}).$$

其 KKT 条件为

$$\mathbf{x}^* = \arg \min_{\mathbf{x}} L(\mathbf{x}, \boldsymbol{\alpha}^*, \boldsymbol{\beta}^*), \quad (7)$$

$$f_i(\mathbf{x}^*) \leq 0, \quad \mathbf{Ax}^* = \mathbf{b}, \quad \alpha_i^* \geq 0, \quad \alpha_i^* f_i(\mathbf{x}^*) = 0. \quad (8)$$

当然, 如果 $f_i(\mathbf{x})$, $i = 0, 1, \dots, m$ 全部可微, 第一个条件就写成

$$\nabla_{\mathbf{x}} L = \nabla_{\mathbf{x}} f_0(\mathbf{x}) + \sum_{i=1}^m \alpha_i \nabla_{\mathbf{x}} f_i(\mathbf{x}) - \mathbf{A}^\top \boldsymbol{\beta} = \mathbf{0}. \quad (9)$$

Proximal operator

对于可微凸函数 $f(\cdot)$ ，其近端算子 (proximal operator) 定义为

$$\text{prox}_f(\boldsymbol{x}) = \arg \min_z f(\boldsymbol{z}) + \frac{1}{2} \|\boldsymbol{z} - \boldsymbol{x}\|_2^2$$

实际含义: 使得 $f(\boldsymbol{z})$ 最小化, 但尽量靠近 \boldsymbol{x} 的最优解.

Projection: a special case of proximal operator

对于非空凸集 \mathcal{C} , 向量 \mathbf{x} 到该集合的投影 (projection) 为

$$\pi_{\mathcal{C}}(\mathbf{x}) = \arg \min_{\mathbf{z} \in \mathcal{C}} \frac{1}{2} \|\mathbf{z} - \mathbf{x}\|_2^2. \quad (10)$$

事实上, 投影就是特定的近端算子:

$$\pi_{\mathcal{C}}(\mathbf{x}) = \text{prox}_{\mathbb{I}(\cdot \in \mathcal{C})}(\mathbf{x}) = \arg \min_{\mathbf{z}} \mathbb{I}(\mathbf{z} \in \mathcal{C}) + \frac{1}{2} \|\mathbf{z} - \mathbf{x}\|_2^2. \quad (11)$$

其中 $\mathbb{I}(\cdot \in \mathcal{C})$ 为示性函数 (indicator function):

$$\mathbb{I}(\mathbf{z} \in \mathcal{C}) = \begin{cases} 0, & \mathbf{z} \in \mathcal{C}, \\ +\infty, & \text{otherwise.} \end{cases} \quad (12)$$

Example: projection onto of L_1 -ball

考虑 L_1 球的投影问题:

$$\pi_{\|\cdot\|_1 \leq \lambda}(\mathbf{x}) = \arg \min_{\mathbf{z}} \frac{1}{2} \|\mathbf{z} - \mathbf{x}\|_2^2, \quad \text{s.t. } \|\mathbf{z}\|_1 \leq \lambda. \quad (13)$$

拉格朗日函数

$$L(\mathbf{z}, \alpha) = \frac{1}{2} \|\mathbf{z} - \mathbf{x}\|_2^2 + \alpha(\|\mathbf{z}\|_1 - \lambda) \quad (14)$$

$$= \left[\frac{1}{2} \|\mathbf{z} - \mathbf{x}\|_2^2 + \alpha \|\mathbf{z}\|_1 \right] - \alpha \lambda. \quad (15)$$

根据 **KKT** 条件可以得到

$$\mathbf{z} = \arg \min_{\mathbf{z}} L(\mathbf{z}, \alpha) = \text{prox}_{\alpha \|\cdot\|_1}(\mathbf{x}), \quad (16)$$

$$\alpha \geq 0, \quad \alpha(\|\mathbf{z}\|_1 - \lambda) = 0. \quad (17)$$

Example: projection onto of L_1 -ball

分类讨论:

- 如果 $\|z\|_1 < \lambda$, 则必有 $\alpha = 0$, 将推出 $z = \text{prox}_{0\|\cdot\|_1}(x) = x$.
- 如果 $\|z\|_1 = \lambda$, 因 $z = \text{prox}_{\alpha\|\cdot\|_1}(x)$, 即 $z_i = \text{sign}(x_i)[|x_i| - \alpha]_+$, 则

$$\|z\|_1 = \sum_{i=1}^n [|x_i| - \alpha]_+ = \lambda. \quad (18)$$

根据以上方程求出 α , 即可求出 z .

Example: projection onto of L_1 -ball

Algorithm 1 $O(n \log n)$ Algorithm for $\pi_{\|\cdot\|_1 \leq \lambda}$

Require: $x \in \mathbb{R}^n, \lambda > 0$.

Ensure: $z = \pi_{\|\cdot\|_1 \leq \lambda}(x)$.

- 1: **if** $\|x\|_1 \leq \lambda$ **then**
 - 2: $z \leftarrow x$.
 - 3: **else**
 - 4: $u \leftarrow \text{sort}(x, \text{'descend'})$,
 - 5: $\rho \leftarrow \max\{j = 1, 2, \dots, n \mid u_j - (\sum_{r=1}^j u_r - \lambda)/j > 0\}$,
 - 6: $\alpha \leftarrow (\sum_{r=1}^\rho u_r - \lambda)/\rho$,
 - 7: $z_i \leftarrow \text{sign}(x_i)[u_i - \alpha]_+, \quad \forall i = 1, 2, \dots, n$.
 - 8: **end if**
-

目录

- 1 Our Problem
- 2 Preliminary
- 3 Methodology**
- 4 Experiments

Projected gradient descent

$$\min_{\mathbf{W}} \|\mathbf{Y} - \mathbf{X}\mathbf{W}\|_2^2, \quad \text{s.t. } \|\mathbf{W}\|_{\infty,1} \leq \tau. \quad (19)$$

迭代更新公式:

$$\mathbf{V} \leftarrow \mathbf{W} - \eta \nabla_{\mathbf{W}} J(\mathbf{W}), \quad (20)$$

$$\mathbf{W} \leftarrow \pi_{\|\cdot\|_{\infty,1} \leq \tau}(\mathbf{V}). \quad (21)$$

问题在于 $\pi_{\|\cdot\|_{\infty,1} \leq \tau}(\mathbf{V})$ 的计算.

Projection and proximal operator

引理

对任意 $\tau > 0$,

$$\text{prox}_{\tau\|\cdot\|_{1,\infty}}(\mathbf{V}) + \pi_{\|\cdot\|_{\infty,1} \leq \tau}(\mathbf{V}) = \mathbf{V} \quad (22)$$

因此问题可以转化为求解 $\text{prox}_{\tau\|\cdot\|_{1,\infty}}(\mathbf{V})$, 即

$$\text{prox}_{\tau\|\cdot\|_{1,\infty}}(\mathbf{V}) = \arg \min_{\mathbf{W}} \tau \|\mathbf{W}\|_{1,\infty} + \frac{1}{2} \|\mathbf{W} - \mathbf{V}\|_2^2. \quad (23)$$

回忆一下:

$$\|\mathbf{W}\|_{1,\infty} = \max_{i=1,2,\dots,m} \|\mathbf{w}^{(i)}\|_1. \quad (24)$$

目录

- 1 Our Problem
- 2 Preliminary
- 3 Methodology
- 4 Experiments**

$L_{\infty,1}$ v.s. $L_{2,1}$?!

Datasets	RFS ($L_{2,1}$)	$L_{\infty,1}$ -regression	SVM
DNA	91.69 \pm 0.97	93.60 \pm 0.59	90.51 \pm 1.31
Binaryalpha	55.27 \pm 2.56	57.53 \pm 1.37	62.81 \pm 1.81
USPS	88.10 \pm 0.51	88.26 \pm 0.38	92.10 \pm 0.59

谢谢!