

# The Fastest $\ell_{\infty,1}$ Prox in the West

Béjar, Benjamín and Dokmanić, Ivan and Vidal, René

汇报人: Apple Zhang

Shenzhen University

2022年9月13日

# 目录

- 1 Our Problem
- 2 Preliminary
- 3 Methodology
- 4 Experiments

# 目录

- 1 Our Problem
- 2 Preliminary
- 3 Methodology
- 4 Experiments

# Sparse regression with $L_{\infty,1}$ constraints

求解以下的回归模型[?]:

$$\min_{\mathbf{W}} \|\mathbf{Y} - \mathbf{X}\mathbf{W}\|_2^2, \quad \text{s.t. } \|\mathbf{W}\|_{\infty,1} \leq \tau. \quad (1)$$

# Recall $L_{p,q}$ -norm

$L_{p,q}$  范数的定义

$$\|\mathbf{W}\|_{p,q} = \left( \sum_{i=1}^m \|\mathbf{w}^{(i)}\|_p^q \right)^{1/q} \quad (2)$$

我们常用的  $L_{2,1}$  范数:

$$\|\mathbf{W}\|_{2,1} = \sum_{i=1}^m \|\mathbf{w}^{(i)}\|_2 \quad (3)$$

本文将用到的  $L_{\infty,1}$ 、 $L_{1,\infty}$  范数:

$$\|\mathbf{W}\|_{\infty,1} = \sum_{i=1}^m \|\mathbf{w}^{(i)}\|_{\infty} = \sum_{i=1}^m \max_{j=1,2,\dots,c} |w_{ij}|, \quad (4)$$

$$\|\mathbf{W}\|_{1,\infty} = \max_{i=1,2,\dots,m} \|\mathbf{w}^{(i)}\|_1. \quad (5)$$

# 目录

1 Our Problem

2 Preliminary

3 Methodology

4 Experiments

# KKT conditions for convex problems

对于以下优化问题, 其中  $f_i(\mathbf{x})$ ,  $i = 0, 1, \dots, m$  均为凸函数.

$$\min_{\mathbf{x}} f_0(\mathbf{x}), \quad \text{s.t. } f_i(\mathbf{x}) \leq 0 \ (i = 1, 2, \dots, m), \quad \mathbf{A}\mathbf{x} = \mathbf{b}. \quad (6)$$

拉格朗日函数

$$L(\mathbf{x}, \boldsymbol{\alpha}, \boldsymbol{\beta}) = f_0(\mathbf{x}) + \sum_{i=1}^m \alpha_i f_i(\mathbf{x}) + \boldsymbol{\beta}^\top (\mathbf{b} - \mathbf{A}\mathbf{x}).$$

其 KKT 条件为

$$\mathbf{x}^* = \arg \min_{\mathbf{x}} L(\mathbf{x}, \boldsymbol{\alpha}^*, \boldsymbol{\beta}^*), \quad (7)$$

$$f_i(\mathbf{x}^*) \leq 0, \quad \mathbf{A}\mathbf{x}^* = \mathbf{b}, \quad \alpha_i^* \geq 0, \quad \alpha_i^* f_i(\mathbf{x}^*) = 0. \quad (8)$$

当然, 如果  $f_i(\mathbf{x})$ ,  $i = 0, 1, \dots, m$  全部可微, 第一个条件就写成

$$\nabla_{\mathbf{x}} L = \nabla_{\mathbf{x}} f_0(\mathbf{x}) + \sum_{i=1}^m \alpha_i \nabla_{\mathbf{x}} f_i(\mathbf{x}) - \mathbf{A}^\top \boldsymbol{\beta} = \mathbf{0}. \quad (9)$$

# Proximal operator

对于可微凸函数  $f(\cdot)$ ，其近端算子 (proximal operator) 定义为

$$\text{prox}_f(x) = \arg \min_z f(z) + \frac{1}{2} \|z - x\|_2^2$$

实际含义: 使得  $f(z)$  最小化, 但尽量靠近  $x$  的最优解.



# Projection: a special case of proximal operator

对于非空凸集  $\mathcal{C}$ , 向量  $\mathbf{x}$  到该集合的投影 (projection) 为

$$\pi_{\mathcal{C}}(\mathbf{x}) = \arg \min_{\mathbf{z} \in \mathcal{C}} \frac{1}{2} \|\mathbf{z} - \mathbf{x}\|_2^2. \quad (10)$$

事实上, 投影就是特定的近端算子:

$$\pi_{\mathcal{C}}(\mathbf{x}) = \text{prox}_{\mathbb{I}(\cdot \in \mathcal{C})}(\mathbf{x}) = \arg \min_{\mathbf{z}} \mathbb{I}(\mathbf{z} \in \mathcal{C}) + \frac{1}{2} \|\mathbf{z} - \mathbf{x}\|_2^2. \quad (11)$$

其中  $\mathbb{I}(\cdot \in \mathcal{C})$  为示性函数 (indicator function):

$$\mathbb{I}(\mathbf{z} \in \mathcal{C}) = \begin{cases} 0, & \mathbf{z} \in \mathcal{C}, \\ +\infty, & \text{otherwise.} \end{cases} \quad (12)$$

# Example: projection onto of $L_1$ -ball

考虑  $L_1$  球的投影问题:

$$\pi_{\|\cdot\|_1 \leq \lambda}(\mathbf{x}) = \arg \min_{\mathbf{z}} \frac{1}{2} \|\mathbf{z} - \mathbf{x}\|_2^2, \quad \text{s.t. } \|\mathbf{z}\|_1 \leq \lambda. \quad (13)$$

拉格朗日函数

$$L(\mathbf{z}, \alpha) = \frac{1}{2} \|\mathbf{z} - \mathbf{x}\|_2^2 + \alpha(\|\mathbf{z}\|_1 - \lambda) \quad (14)$$

$$= \left[ \frac{1}{2} \|\mathbf{z} - \mathbf{x}\|_2^2 + \alpha \|\mathbf{z}\|_1 \right] - \alpha \lambda. \quad (15)$$

根据 **KKT** 条件可以得到

$$\mathbf{z} = \arg \min_{\mathbf{z}} L(\mathbf{z}, \alpha) = \text{prox}_{\alpha \|\cdot\|_1}(\mathbf{x}), \quad (16)$$

$$\alpha \geq 0, \quad \alpha(\|\mathbf{z}\|_1 - \lambda) = 0. \quad (17)$$

# Example: projection onto of $L_1$ -ball

分类讨论:

- 如果  $\|z\|_1 < \lambda$ , 则必有  $\alpha = 0$ , 将推出  $z = \text{prox}_{0\|\cdot\|_1}(x) = x$ .
- 如果  $\|z\|_1 = \lambda$ , 因  $z = \text{prox}_{\alpha\|\cdot\|_1}(x)$ , 即  $z_i = \text{sign}(x_i)[|x_i| - \alpha]_+$ , 则

$$\|z\|_1 = \sum_{i=1}^n [|x_i| - \alpha]_+ = \lambda. \quad (18)$$

根据以上方程求出  $\alpha$ , 即可求出  $z$ .

# Example: projection onto of $L_1$ -ball

---

**Algorithm 1**  $O(n \log n)$  Algorithm for  $\pi_{\|\cdot\|_1 \leq \lambda}$

---

**Require:**  $x \in \mathbb{R}^n, \lambda > 0$ .

**Ensure:**  $z = \pi_{\|\cdot\|_1 \leq \lambda}(x)$ .

- 1: **if**  $\|x\|_1 \leq \lambda$  **then**
  - 2:    $z \leftarrow x$ .
  - 3: **else**
  - 4:    $u \leftarrow \text{sort}(x, \text{'descend'})$ ,
  - 5:    $\rho \leftarrow \max\{j = 1, 2, \dots, n \mid u_j - (\sum_{r=1}^j u_r - \lambda)/j > 0\}$ ,
  - 6:    $\alpha \leftarrow (\sum_{r=1}^{\rho} u_i - \lambda)/\rho$ ,
  - 7:    $z_i \leftarrow \text{sign}(x_i)[u_i - \alpha]_+, \quad \forall i = 1, 2, \dots, n$ .
  - 8: **end if**
-

# 目录

1 Our Problem

2 Preliminary

3 Methodology

4 Experiments

# Projected gradient descent

$$\min_{\mathbf{W}} \|\mathbf{Y} - \mathbf{X}\mathbf{W}\|_2^2, \quad \text{s.t. } \|\mathbf{W}\|_{\infty,1} \leq \tau. \quad (19)$$

迭代更新公式:

$$\mathbf{V} \leftarrow \mathbf{W} - \eta \nabla_{\mathbf{W}} J(\mathbf{W}), \quad (20)$$

$$\mathbf{W} \leftarrow \pi_{\|\cdot\|_{\infty,1} \leq \tau}(\mathbf{V}). \quad (21)$$

问题在于  $\pi_{\|\cdot\|_{\infty,1} \leq \tau}(\mathbf{V})$  的计算.

# Projection and proximal operator

## 引理

对任意  $\tau > 0$ ,

$$\text{prox}_{\tau\|\cdot\|_{1,\infty}}(\mathbf{V}) + \pi_{\|\cdot\|_{\infty,1}\leq\tau}(\mathbf{V}) = \mathbf{V} \quad (22)$$

因此问题可以转化为求解  $\text{prox}_{\tau\|\cdot\|_{1,\infty}}(\mathbf{V})$ , 即

$$\text{prox}_{\tau\|\cdot\|_{1,\infty}}(\mathbf{V}) = \arg \min_{\mathbf{W}} \tau \|\mathbf{W}\|_{1,\infty} + \frac{1}{2} \|\mathbf{W} - \mathbf{V}\|_2^2. \quad (23)$$

回忆一下:

$$\|\mathbf{W}\|_{1,\infty} = \max_{i=1,2,\dots,m} \|\mathbf{w}^{(i)}\|_1. \quad (24)$$

# 目录

- 1 Our Problem
- 2 Preliminary
- 3 Methodology
- 4 Experiments**



# $L_{\infty,1}$ v.s. $L_{2,1}$ ?!

Datasets	RFS ( $L_{2,1}$ )	$L_{\infty,1}$ -regression	SVM
DNA	91.69 $\pm$ 0.97	93.60 $\pm$ 0.59	90.51 $\pm$ 1.31
Binaryalpha	55.27 $\pm$ 2.56	57.53 $\pm$ 1.37	62.81 $\pm$ 1.81
USPS	88.10 $\pm$ 0.51	88.26 $\pm$ 0.38	92.10 $\pm$ 0.59

# 谢谢!